




Chapitre 2

Techniques de clustering



Plan


- Proximité
- Types de variables
- Principales approches du clustering
 - Méthodes par partitionnement
 - Méthodes hiérarchiques

Introduction

Classification **non supervisée**: Classes non prédéfinies a priori




Regroupement des objets en **des clusters** formant les classes.



Cluster 1

Cluster 2



Cluster 3

Maximiser **la similarité** au sein du même groupe (intra-classe).
Minimiser **la similarité** au sein des groupes différents (inter-classe).

Applications

☐ Marketing

Segmentation
des marchés

Divers
domaines

☐ Reconnaissance des formes

Gènes
semblables

☐ Bio-informatique

Textes
proches

☐ Textmining

Groupes d'accès
similaires


☐ Web mining

■

■



Proximité



Proximité

☐ Mesure de similarité

➡ Plus la mesure est grande, plus les éléments sont similaires.

☐ Mesure de dissimilarité

➡ Plus la mesure est faible, plus les éléments sont similaires.

Ces mesures sont souvent exprimées en fonction d'une distance qui change selon la nature des variables (continues, catégoriques,...)

Structure de données

- Matrice de données


$$\begin{bmatrix} x_{11} & \dots & x_{1j} & \dots & x_{1n} \\ \dots & \dots & \dots & \dots & \dots \\ x_{i1} & \dots & x_{ij} & \dots & x_{in} \\ \dots & \dots & \dots & \dots & \dots \\ x_{m1} & \dots & x_{mj} & \dots & x_{mn} \end{bmatrix}$$

- Matrice de similarité

$$\begin{bmatrix} 0 & & & & \\ D(2,1) & 0 & & & \\ D(3,1) & D(3,2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ D(m,1) & D(m,2) & \dots & \dots & 0 \end{bmatrix}$$



Types de variables



Types de variables

- ☐ Numériques (Poids, Taille, ...)
- ☐ Binaires (Service militaire, Option, ...)
- ☐ Catégoriques (Couleur, Situation familiale, ...)
- ☐ Ordinales (Résultat d'un concours, Qualité d'un produit, ...)

Variables numériques continues

□ Distance Euclidienne

$$D(X, Y) = [(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2]^{1/2}$$

□ Distance de Minkowski

$$D(X, Y) = [(x_1 - y_1)^q + (x_2 - y_2)^q + \dots + (x_n - y_n)^q]^{1/q} \quad q > 0$$

➡ Généralisation de la distance Euclidienne

□ Distance de Manhattan

$$D(X, Y) = |x_1 - y_1| + |x_2 - y_2| + \dots + |x_n - y_n|$$

➡ Cas particulier de la distance Minkowski ($q = 1$)

Exemple

	Age	Nombre Enfants	Salaire
P1	40	2	1000
P2	75	4	600
P3	50	3	1100
P4	35	1	550

Distance Euclidienne

$$D(P1, P2) = ((-35)^2 + (-2)^2 + (400)^2)^{1/2} = 401.53$$

$$D(P1, P3) = ((-10)^2 + (-1)^2 + (-100)^2)^{1/2} = 100.5$$

$$D(P1, P4) = ((5)^2 + (1)^2 + (450)^2)^{1/2} = 450.03$$



P1 est plus proche de P3 que de P2 et P4

Distance de Manhattan

$$D(P1, P2) = |-35| + |-2| + |400| = 437$$

$$D(P1, P3) = |-10| + |-1| + |-100| = 111$$

$$D(P1, P4) = |5| + |1| + |450| = 456$$

On peut aussi normaliser



P1 est plus proche de P3 que de P2 et P4

Normalisation

$$x'_i = \frac{x_i - \min x_i}{\max x_i - \min x_i}$$

	Age	Nombre Enfants	Salaire
P1	40	2	1000
P2	75	4	600
P3	50	3	1100
P4	35	1	550



	Age	Nombre Enfants	Salaire
P1	0.125	0.333	0.818
P2	1	1	0.09
P3	0.375	0.666	1
P4	0	0	0

Distance Euclidienne

$$D(P1, P2) = ((-0.875)^2 + (-0.667)^2 + (0.728)^2)^{1/2} = 1.319$$

$$D(P1, P3) = ((-0.25)^2 + (-0.333)^2 + (-0.182)^2)^{1/2} = 0.454$$

$$D(P1, P4) = ((0.125)^2 + (0.333)^2 + (0.818)^2)^{1/2} = 0.891$$



P1 est plus proche de P3 que de P2 et P4

Distance de Manhattan

$$D(P1, P2) = |-0.875| + |-0.667| + |0.728| = 2.27$$

$$D(P1, P3) = |-0.25| + |-0.333| + |-0.182| = 0.765$$

$$D(P1, P4) = |0.125| + |0.333| + |0.818| = 1.276$$



P1 est plus proche de P3 que de P2 et P4

Variables binaires

Table de contingence

		O_j		
		1	0	Σ
O_i	1	a	b	$a+b$
	0	c	d	$c+d$
Σ		$a+c$	$b+d$	p

a = nombre de positions où i est à 1 et j est à 1

$$O_i = (1, 0, 1, 1, 1) \quad O_j = (1, 0, 1, 0, 0) \quad \Rightarrow \quad a=2, b=2, c=0, d=1$$

Coefficient de Russel et Rao (Proportion d'occurrences positives):

$$D(O_i, O_j) = \frac{a}{a+b+c+d} = 2/5$$

Coefficient de Jaccard (Poids des occurrences fausses est neutralisé) :

$$D(O_i, O_j) = \frac{a}{a+b+c} = 1/2$$

Coefficient de Dice (Poids double pour les occurrences vraies) :

$$D(O_i, O_j) = \frac{2a}{2a+b+c} = 2/3$$

Variables catégoriques

□ Généralisation des variables binaires.

- **Méthode 1:** Utiliser un grand nombre de variables binaires.



Créer une variable binaire pour chaque modalité
(ex: variable rouge qui prend les valeurs vraie ou fausse)

- **Méthode 2:** Matching simple

m: Nombre de ressemblances,
p: Nombre total de variables


$$D(O_i, O_j) = \frac{p-m}{p}$$



Principales approches de clustering

Principales approches

Cluster



**Méthodes par
partitionnement**




Diviser un ensemble de
N objets en k clusters

**Méthodes
hiérarchiques**




Création d'une décomposition
hiérarchique des objets
selon certains critères



Méthodes par partitionnement

- ☐ Construire à partir des objets de l'ensemble d'apprentissage k clusters.
- ☐ Trouver une partition en k clusters en optimisant la fonction de similarité (critère de partitionnement).
- ☐ Approches:
 - ☐ **Global optimal**: Considérer toutes les k partitions.
 - ☐ **k-means**: Chaque cluster est représenté par son centre.
 - ☐ **k-medoids**: Chaque cluster est représenté par un de ses objets.



Méthode k-moyenne (k-means)

K-moyenne (Forgy 1965, MacQueen 1967)

- ☐ Choisir le nombre de clusters et une mesure de distance.
- ☐ Construire une partition aléatoire comportant k clusters non vides.
- ☐ Répéter
 - ☐ Calculer le centre de chaque cluster de la partition.
 - ☐ Assigner chaque objet au cluster dont le centre est plus proche (distance).

Jusqu'à ce que la partition soit stable.

Exemple: k-moyenne (1)

$T = \{2, 4, 6, 7, 8, 11, 13\}$

D = distance Euclidienne

- Choisir 3 clusters au hasard à partir de T :

$C_1 = \{2\}$, $M_1 = 2$,

$C_2 = \{4\}$, $M_2 = 4$,

$C_3 = \{6\}$, $M_3 = 6$


- Les autres objets de T sont affectés au cluster C_3 puisque $D(O, M_3)$ est minimale.

- On aura:

$C_1 = \{2\}$, $M_1 = 2$,

$C_2 = \{4\}$, $M_2 = 4$,

$C_3 = \{6, 7, 8, 11, 13\}$, $M_3 = 45/5 = 9$



Exemple: k-moyenne (2)

□ $D(6, M_2) < D(6, M_3)$


➔ 6 passe au cluster C_2 : les autres objets restent dans leurs clusters.

□ On aura:

$$C_1 = \{2\}, M_1 = 2,$$

$$C_2 = \{4, 6\}, M_2 = 10/2 = 5$$

$$C_3 = \{7, 8, 11, 13\}, M_3 = 39/4 = 9.75$$



Exemple: k-moyenne (3)

□ $D(7, M_2) < D(7, M_3)$


➔ 7 passe au cluster C_2 : les autres objets restent dans leurs clusters.

□ On aura:

$$C_1 = \{2\}, M_1 = 2,$$

$$C_2 = \{4, 6, 7\}, M_2 = 17/3 = 5.66,$$

$$C_3 = \{8, 11, 13\}, M_3 = 32/3 = 10.66$$



Exemple: k-moyenne (4)

□ $D(8, M_2) < D(8, M_3)$


➡ 8 passe au cluster C_2 : les autres objets restent dans leurs clusters.

□ On aura:

$$C_1 = \{2\}, M_1 = 2,$$

$$C_2 = \{4, 6, 7, 8\}, M_2 = 25/4 = 6.25,$$

$$C_3 = \{11, 13\}, M_3 = 24/2 = 12$$



Exemple: k-moyenne (5)

□ $D(4, M_1) < D(4, M_2)$


➡ 4 passe au cluster C_1 : les autres objets restent dans leurs clusters.

□ On aura:


$C_1 = \{2, 4\}$, $M_1 = 3$,

$C_2 = \{6, 7, 8\}$, $M_2 = 21/3 = 7$,

$C_3 = \{11, 13\}$, $M_3 = 24/2 = 12$



La partition est stable.



Attention !!

- ☐ K-moyenne est appelée aussi **méthode des centres mobiles**.

- ☐ Si on a plusieurs attributs

 - ➔ Nécessité de normaliser les échelles des différents attributs.

- ☐ Choix du nombre de classes k dépend de l'utilisateur.

- ☐ Résultat dépendant des clusters initiaux choisis.


 - ➔ Faire plusieurs expérimentations avec différents clusters initiaux et choisir la meilleure configuration.

- ☐ Plusieurs variantes de K-moyenne:

 - ☐ **Sélection des k clusters initiaux.**

 - ☐ **Mesure de la distance utilisée.**


 - ☐ **Calcul de la moyenne des clusters.**



k-modes

k-modes (Huang 1997)

- ☐ Traitement des données catégoriques.
- ☐ Au lieu de la moyenne, on va utiliser le mode.
- ☐ Utilisation plutôt du simple matching.
- ☐ Utilisation d'une méthode basée sur les fréquences pour mettre à jour les modes.



Exemple: k-modes (1)

k=3,

Initialisation

$C1=\{O1\}$; $C2=\{O2\}$; and $C3=\{O3\}$

Les trois clusters sont:

$C1=(\text{Finance}, \text{Élevé}, A)$;

$C2=(\text{Finance}, \text{Faible}, B)$;

$C3=(\text{Marketing}, \text{Moyen}, C)$.

	Department	Revenu	Catégorie
O1	Finance	Elevé	A
O2	Finance	Faible	B
O3	Marketing	Moyen	C
O4	Comptabilité	Moyen	C
O5	Marketing	Faible	B
O6	Finance	Elevé	A
O7	Comptabilité	Faible	B
O8	Marketing	Moyen	C

Exemple: k-modes (2)

c'est le simple
matching


□ Pour chaque objet, calculer $d(O_i, C_l)$, $l=1,2,3$

O4 est affecté à C_3 puisque $d(O_4, C_3)$ est minimale.

O5 est affecté à C_2 puisque $d(O_5, C_2)$ est minimale.

.

.



Exemple: k-modes (3)

□ Mise à jour des modes

$C_1 = (\text{Finance}, \text{Élevé}, A);$

$C_2 = (\text{Finance}, \text{Faible}, B)$ ou $C_2 = (\text{Marketing}, \text{Faible}, B)$ ou
 $C_2 = (\text{Comptabilité}, \text{Faible}, B);$


$C_3 = (\text{Marketing}, \text{Moyen}, C).$


Choix arbitraire



Recalcul des dissimilarités des objets $\Rightarrow$ Les objets n'ont pas changé de clusters.

La partition est stable.





Travail à faire


Soit l'ensemble d'apprentissage suivant où chaque objet est caractérisé par l'attribut âge.

Objet	O1	O2	O3	O4	O5	O6	O7	O8	O9	O10	O11	O12
Age	27	51	52	33	45	22	28	44	40	38	20	57

En supposant que le nombre de clusters est égal à 3 ($k = 3$). Trouver la composition finale des clusters en appliquant la méthode k-moyenne sur cet ensemble d'apprentissage et en détaillant les différents calculs à chaque étape.

Il est à noter que la distance à utiliser est celle de Manhattan et que la partition initiale des clusters est la suivante :

$C1 = \{O1\}$; $C2 = \{O2\}$; $C3 = \{O3\}$




Clustering incrémental

- Les bases de données sont dynamiques:

L'ensemble des objets
L'ensemble des attributs

} Evoluent dans le temps



« Incremental Clustering » pour résoudre le problème de la maintenance des clusters.

😊 Réduction du coût de l'incorporation de la nouvelle information.

Méthode hiérarchique


□ Certains objets peuvent avoir naturellement plusieurs niveaux de regroupement.



□ Réaliser plusieurs niveaux de fonctionnement.

□ Puis utiliser le niveau nécessaire à l'application.


Exploitation de ces niveaux dans la classification



Méthode hiérarchique: Par divisions

Par divisions = top-down

- ☐ Tous les objets constituent un unique cluster.
- ☐ Séparer les objets (clusters) les plus dissimilaires (grande distance).




- ☐ Tous les objets sont des concepts feuilles.
- ☐ Ou une condition est vérifiée.


Méthode hiérarchique: Par agglomérations

Par agglomérations = Bottom-up

- ☐ Chaque objet constitue un cluster.
- ☐ Regrouper les objets (clusters) les plus proches (distance) en des clusters.



- ☐ Arriver à un concept sommet.
- ☐ Ou une condition est vérifiée (on arrive au nombre k de clusters).



Exemple

- Regrouper ensemble tous les objets dont la distance est inférieure ou égale à 4.

	P1	P2	P3	P4
P1	0			
P2	1	0		
P3	7	5	0	
P4	2	3	6	0

- On considère que la distance entre un objet O_i et un ensemble d'objets I est le minimum des distances de O_i par rapport à chaque objet de I .

Étape 1

- On a un ensemble constitué de 4 objets:
 $\{P1, P2, P3, P4\}$
- On va essayer de constituer le premier cluster regroupant les objets les plus proches.

	P1	P2	P3	P4
P1	0			
P2	1	0		
P3	7	5	0	
P4	2	3	6	0



	{P1, P2}	P3	P4
{P1,P2}	0		
P3	5	0	
P4	2	6	0

Premier cluster {P1, P2}
{{P1, P2}, P3, P4}

Étape 2

- On va chercher le deuxième cluster.
- Les objets les plus proches sont $\{P1, P2\}$ et $P4$.
- On recalcule la matrice de distances:

	$\{P1, P2\}$	P3	P4
$\{P1, P2\}$	0		
P3	5	0	
P4	2	6	0



	$\{P1, P2, P4\}$	P3
$\{P1, P2, P4\}$	0	
P3	5	0


Deuxième cluster $\{P1, P2, P4\}$


Exemple

□ $D(\{P1, P2, P4\}, P3) = 5 > 4$

□ On a différents niveaux de clusters:

1. On a $\{P1, P2, P3, P4\}$
2. Puis $\{\textcolor{red}{P1}, \textcolor{red}{P2}\}, P3, P4\}$
3. Puis $\{\textcolor{red}{P1}, \textcolor{red}{P2}, \textcolor{red}{P4}\}, P3\}$





Travail à faire

On suppose qu'on a six villes (V1, V2, V3, V4, V5, V6) telles que la matrice suivante représente les distances en kilomètres par paire de villes.

	V1	V2	V3	V4	V5	V6
V1	0	662	877	255	412	996
V2	662	0	295	468	268	400
V3	877	295	0	754	564	138
V4	255	468	754	0	219	869
V5	412	268	564	219	0	669
V6	996	400	138	869	669	0

Appliquer l'algorithme de clustering hiérarchique par agglomérations sur cet ensemble de villes, en se basant sur la matrice des distances ci-dessus. Il est à noter que la distance entre une ville V_i et un ensemble de villes est le minimum des distances de V_i par rapport à chaque ville de cet ensemble de villes. La condition d'arrêt est quand toutes les distances restantes entre les villes sont strictement supérieures à 300 ou quand on arrive à un seul cluster.

Solution (1)

	V1	V2	V3	V4	V5	V6
V1	0	662	877	255	412	996
V2	662	0	295	468	268	400
V3	877	295	0	754	564	138
V4	255	468	754	0	219	869
V5	412	268	564	219	0	669
V6	996	400	138	869	669	0

	V1	V2	V3/V6	V4	V5
V1	0	662	877	255	412
V2	662	0	295	468	268
V3/V6	877	295	0	754	564
V4	255	468	754	0	219
V5	412	268	564	219	0


Solution (2)

	V1	V2	V3/V6	V4/V5
V1	0	662	877	255
V2	662	0	295	268
V3/V6	877	295	0	564
V4/V5	255	268	564	0

	V1/V4/V5	V2	V3/V6
V1/V4/V5	0	268	564
V2	268	0	295
V3/V6	564	295	0

	V1/V4/V5/V2	V3/V6
V1/V4/V5/V2	0	295
V3/V6	295	0

Voilà à la fin on aura un seul cluster V1/V4/V5/V2/V3/V6.



Conclusion

- ☐ Utilisables dans plusieurs applications.
 - ☐ Possibilité de vérification des résultats de clustering par d'autres techniques de classification supervisée.
 - ☐ Plusieurs extensions de k-means et k-modes:
 - ☐ Soft k-means.
 - ☐ Fuzzy k-means.
 - ☐ Belief k-modes.
 - ☐ Possibilistic k-modes.
- -
 -